東南大學成賢學院
校团委科创部大学生科学技术协会（计算机分会）

计往开来 CXCS Horizon

2026 年 第 1 期 创刊号

本期看点

权重空间编程的星星之火

大语言模型原生读写神经网络权重

新　闻　苹果推出 MacBook Pro PROLED

小剧场　柊凛亜蘭的一天

MENU 01

CONTENTS

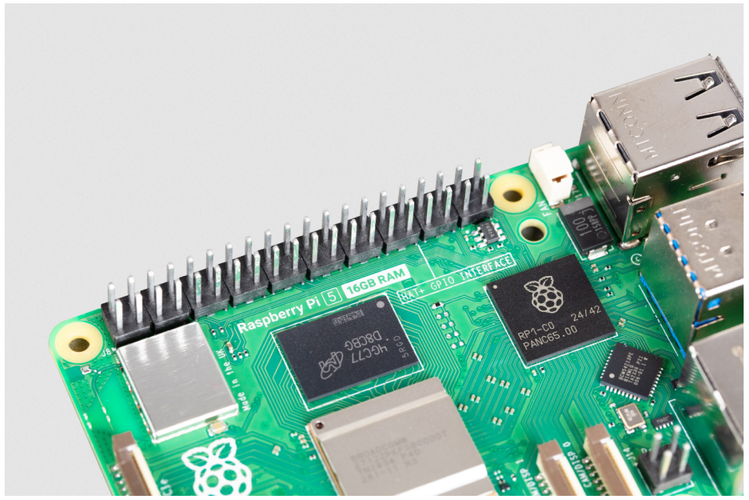

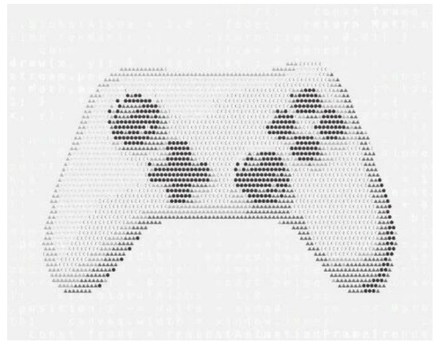

01 视界 Horizon
捕捉科技世界的最新信号

06 精研 Craftsmanship
探究技术细节与系统架构的精妙

06 权重空间编程的星星之火：大语言模型原生读写神经网络权重
01 DeepInfre：来自 Deepseek 的高性能推理框架
01 百 TB 内存是怎么省出来的：1.1.1.1 DNS 缓存优化实录
01 Bun in Rust: 用 Rust 重写 Bun
01 本期开源推荐：TTY7

01 算法 Algorithm
“算法”与“法则”的结合

01 漫话 Off-by-One
技术闲谈、趣梗和日常温度

主 编 辑 贾宇辰
副 主 编 孙博文
责任编辑 刘佳昊 王启轩
美术编排 贾宇辰
发 行 东南大学成贤学院计算机协会
翻译校对 DeepSeek v4.1

CONTENTS

MENU 02

01

币安遭大规模黑客攻击，约 63 亿美元数字资产被转移

10 月 29 日（UTC），加密货币交易所币安遭遇大规模网络攻击，约 63 亿美元数字资产被未经授权地转出，涉及比特币、XRP、SOL 等多种资产。币安随后暂停相关资金出入功能，并开展资产冻结、拦截与追踪。公司表示，将以自有资金等承担相关损失。上述金额为币安通报及媒体转述的口径，最终认定损失仍可能随追回进展调整。

此次攻击的链条延伸至开发者工作环境与钱包签名服务。攻击者并不只是窃取单个用户密码，还利用工程师设备与内部系统权限绕过正常提现流程发起转账；这暴露出开发终端失陷可向核心资产系统扩散的风险。

在 11 月 3 日公布的初步调查中，币安称，攻击者通过搜索引擎付费钓鱼网站诱导一名工程师安装被篡改的 Homebrew，并以虚假招聘面试为由，要求另一名工程师运行含恶意程序的代码仓库；随后借助受感染设备与窃取的凭据进入内部系统，最终取得钱包签名服务的未授权访问权限。该调查结论由币安单方公布。

02

国行 Apple 智能进入 iOS 27.3 开发者测试，接入阿里千问

据凤凰网科技 11 月 4 日报道，苹果在 iOS 27.3 开发者测试版中面向中国用户开放部分 Apple 智能功能。使用兼容设备的开发者更新系统后，可体验写作工具、实时翻译、视觉智能、照片消除及智绘表情等功能。

苹果与阿里巴巴合作，在 Siri、写作工具等功能中加入千问大模型支持：用户可将部分 Siri 请求转交千问处理，也可针对照片、PDF 和演示文稿提问，或通过写作工具生成、改写和整理文本。首批功能还包括邮件与通知摘要，以及照片应用中的自然语言搜索等。

此次开放属于开发者测试，并未包含苹果在 WWDC 2026 公布的全部新一代 Apple 智能功能。按照苹果此前公布的安排，这批功能预计于 12 月随 iOS 27.3 正式版向中国用户推出，具体日期与功能清单仍以苹果后续公告为准。

03

OpenAI 发布 GPT-6 Cyber，漏洞研究能力与使用边界同步受关注

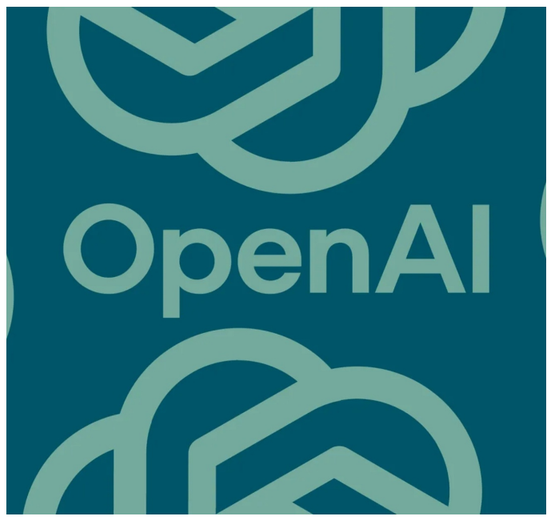

11 月 6 日（北京时间），OpenAI 发布网络安全模型 GPT-6 Cyber，面向获得授权的防御性安全研究。据公司披露，新模型在测试漏洞利用能力的 ExploitGym 基准中得分 48.5%，高于前代 GPT-5.6 Cyber 的 32.1%，并协助研究人员发现 Firefox 中 81 个此前未知的漏洞。

除漏洞研究能力外，模型能否遵守授权范围也是此次发布的重点。OpenAI 称，在相关边界测试中，GPT-6 Cyber 的越界比例由前代约 5% 降至不足 1%。上述数字均来自 OpenAI 自行公布的评测，尚无第三方复现，实际部署中的表现仍可能因使用方式与限制条件而异。

OpenAI 将 GPT-6 Cyber 列入其准备度框架的网络安全“Critical”等级。模型先向部分 Daybreak Red 项目客户开放，公司计划在后续数周扩大访问范围，并通过使用检查与访问限制降低滥用风险。

04

月之暗面开放 Kimi K3.1 Pro 权重，支持百万 token 上下文

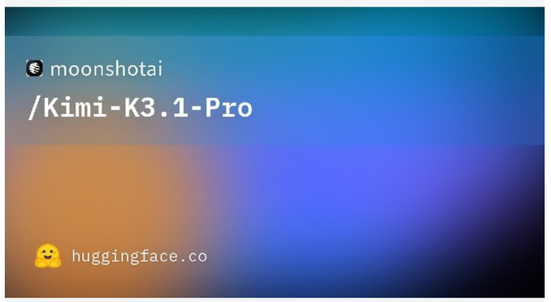

月之暗面在 Hugging Face 发布 Kimi K3.1 Pro 模型权重。该模型采用混合专家（MoE）架构，总参数量 2.8 万亿，激活参数约 1040 亿，支持约 100 万 token 上下文以及文本、图像输入，定位于多模态智能体任务。

根据官方模型卡，Kimi K3.1 Pro 在 Kimi K3 基础上进行大规模联合强化学习，重点改进编程、3D 创作、金融研究、事实准确性及复杂任务执行能力。官方同步提供 API，开发者可通过兼容 OpenAI 和 Anthropic 接口的方式接入。

模型以量化权重形式发布，并采用专门的 Kimi K3.1 Pro License。开放权重为研究、评测和自主部署增加了选择，但实际部署仍需满足相应的算力、内存及许可证要求；模型卡中的性能数据为厂商自测结果，应结合具体评测条件理解，商用前宜单独核对许可条款。

05

musl 与 OpenSSH 交互缺陷曝光，特定配置下可绕过 SSH 认证

安全研究者发现，musl C 库与 OpenSSH 的密码验证逻辑在特定配置下存在交互缺陷，攻击者可能在不知道目标账户密码的情况下登录服务器。受影响环境需同时满足：使用 musl、未启用 PAM、开启密码认证，且目标账户的口令记录满足特定条件；Alpine Linux 的部分部署属于影响范围。

问题与异常长密码的错误处理有关：musl 的密码散列函数在部分情形下返回表示失败的特殊值，而 OpenSSH 的比较逻辑可能将其误判为与目标账户记录一致，进而错误接受登录。攻击者仍需掌握有效账户名，并能通过网络连接到 SSH 服务，因此不属于无需任何前提的远程批量利用。

该漏洞不影响所有 Linux 系统。采用 glibc，或通过 PAM 执行相应认证的环境不受这一路径影响；OpenWrt 默认使用的 Dropbear 也不在此次范围之内。OpenSSH 已于 11 月 5 日发布 10.6p2，Alpine 同步提供修复包；在完成升级前，关闭密码认证可作为临时缓解措施。

06

Anthropic 开源 FlashProve 研究原型，尝试证明 AI 输出来自哪个模型

Anthropic 公布 FlashProve 研究进展，并开放技术规范与部分工作代码，尝试通过密码学证明验证一段 AI 输出是否来自指定模型。据 TechCrunch 报道，该研究针对模型服务中的身份核验问题，例如服务商是否在用户不知情时替换模型，以及第三方能否证明某项任务确由其宣称的模型完成。

按照研究设想，模型提供方需发布可用于核验的模型“指纹”，后续输出再通过相应证明与指纹建立对应关系。指纹无需公开模型权重，因而也可用于闭源商业模型；系统设计还考虑了在本地设备执行验证的可能性。

FlashProve 目前仍属研究原型，尚未经过同行评审，Anthropic 也未公布在自身或其他实验室部署的时间表。它提供的是验证模型身份与推理来源的技术方向，不能据此保证模型回答本身正确，也尚不能让用户直接检测所有现有 AI 服务。

07

《千恋＊万花》全球累计销量突破 100 万份，宣布电视动画改编

11 月 5 日，电视动画《千恋＊万花》官方账号发布公告，宣布柚子社（Yuzusoft）旗下同名游戏全球累计销量突破 100 万份，并确认作品将改编为电视动画。官方同时公开原作画师こぶいち绘制的纪念插画，后续制作信息将另行公布。

这项销量数据来自官方公告口径，反映了该视觉小说作品的长期商业表现；原作游戏于 2016 年发行。此次动画改编将原有游戏内容延伸至电视动画媒介，成为其 IP 运营的新进展。公告未披露分地区、分平台销量及对应销售收入，也未在该帖中公布动画播出时间。

08

苹果推出 MacBook Pro PROLED 版串联 OLED 与触控进入 Mac

10 月 28 日，苹果发布配备 PROLED XDR 显示屏的新款 MacBook Pro，提供 14 英寸和 16 英寸机型，搭载 M5 Pro 或 M5 Max 芯片。新机采用串联 OLED 技术，并首次为 Mac 带来屏幕触控，灵动岛也随之进入 Mac 界面。

据苹果介绍，PROLED XDR 显示屏支持最高 2000 尼特峰值 HDR 与 SDR 亮度、最高 120Hz 自适应刷新率，以及 P3 和 Adobe RGB 色域，面向摄影、设计、视频调色等专业工作。用户可通过触控完成缩放、拖放及部分创作操作，并与键盘、触控板配合使用。

新机最高可选配 128GB 统一内存与 16TB 存储，苹果标称电池续航最长 24 小时。美国市场 14 英寸 M5 Pro 机型起价 2899 美元，16 英寸机型起价 3399 美元，均为不含税起售价；新品 11 月 6 日起交付。显示与续航数据均为苹果公布的规格或实验室测试结果，实际表现随配置和使用场景变化。

09

Linux 7.4 首个候选版本发布，AI 辅助补丁逐渐进入常规开发流程

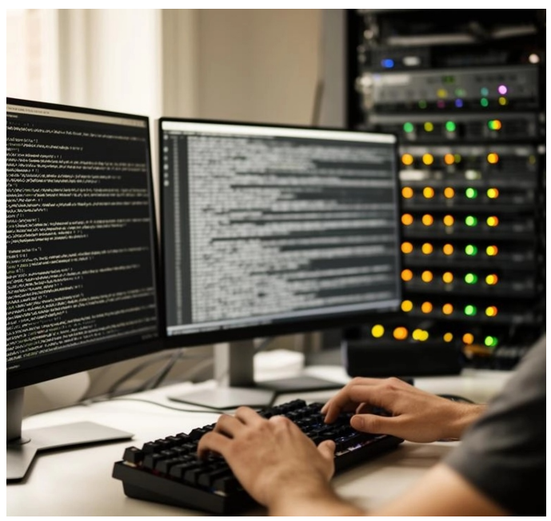

11 月 1 日，Linux 7.4-rc1 发布，标志着这一版本完成合并窗口并进入后续测试阶段。据 BigGo 报道，本轮合并包含近 2 万次提交，高于通常约 1.5 万次的规模，更新涉及处理器、图形驱动及其他硬件支持。

Linus Torvalds 在 rc1 发布说明中表示，他更乐见由 AI 发现问题或提出修改建议的工作进入合并窗口、接受常规审查，而不是主要在后续候选版本阶段以额外修复的形式集中出现。他将这种变化称为更健康的开发模式，同时指出，不少 AI 建议的补丁仍需由人类开发者重新编写。

需要说明的是，提交量增长并不意味着这些修改全部由 AI 生成，版本可能成为长期支持版本的预期也可能影响贡献规模；近 2 万次提交为媒体统计口径，与 Torvalds 的评论并非同一事项。Linux 7.4 目前仍处于候选测试阶段，其最终发布与长期支持安排需以后续公告为准。

10

《GTA VI》11 月 10 日开放预载，文件容量最高达 212GB

Rockstar Games 宣布，《Grand Theft Auto VI》（《GTA VI》）数字版将于 11 月 10 日开放预载，并于 11 月 19 日登陆 PlayStation 5 和 Xbox Series X|S。官方表示，预载文件容量因设备不同而有所差异，最高可达 212GB，玩家需提前预留相应存储空间。

PS5 版预载按玩家所在时区的 11 月 10 日午夜开启；Xbox Series X|S版则全球统一于 GMT 0 点开启，即北京时间 11 月 10 日上午 8 点。两种主机平台含下载码的盒装版本预计于 11 月 12 日起在零售渠道销售。

官方还将在 11 月 19 日通过网站免费提供可打印的封面海报和 Leonida 地图。此次公告明确了发售前的下载安排与存储需求；预载完成并不意味着游戏提前解锁，实际游玩仍需等待正式发售。

权重空间编程的星星之火：大语言模型原生读写神经网络权重

作者 Rikiya Takehi, Jayden Teoh, Alex Zhang, Omar Khattab
翻译 DeepSeek v4.1

TL;DR;

我们发现，前沿大语言模型非常擅长原生地读写神经网络权重，无论是借助近期涌现的各种工具与算法，还是直接编辑权重。这些结果表明，权重空间编程（Weight-Space Programming）已初现星火，其能力可能超出我们对人类或常规算法的预期。这对优化与可解释性两方面，都可能意义重大。

仅仅看着原始权重，GPT-6 Astra 就能说出一个网络当初是被训练来做什么的。而在没有任何环境反馈的情况下，它也能毫不费力地从零写出小型游戏网络，其表现胜过用 PPO 训练了 1 亿步的网络。

同样，在被要求「不用梯度让 Qwen3.5-0.8B 的数学更好」时，Astra 在它的权重里找出一处问题，正是这处问题导致推理死循环——Qwen 自己的模型卡对此也有警示——并通过原生编辑 0.016% 的权重把它修好。在相同的采样设置下，这次权重修正把 MATH-500 从 7.9% 提升到 48.1%，还开箱即用地泛化到指令遵循上，使 IFEval 提升至 3 倍。

这一切都不需要让 Astra 编写训练循环。它用自己的推理去弄清神经网络的每一部分在计算什么、或者应该计算什么，再据此修改权重。我们称这种能力为权重空间编程。

在深度学习的整个历史中，我们把自己那套朴素的归纳偏置，编码进 Adam 或 Muon 这类微小的符号优化器里。这一点正在改变：我们的神经网络权重，很快就会由那些会针对权重进行推理的大语言模型来原生优化。

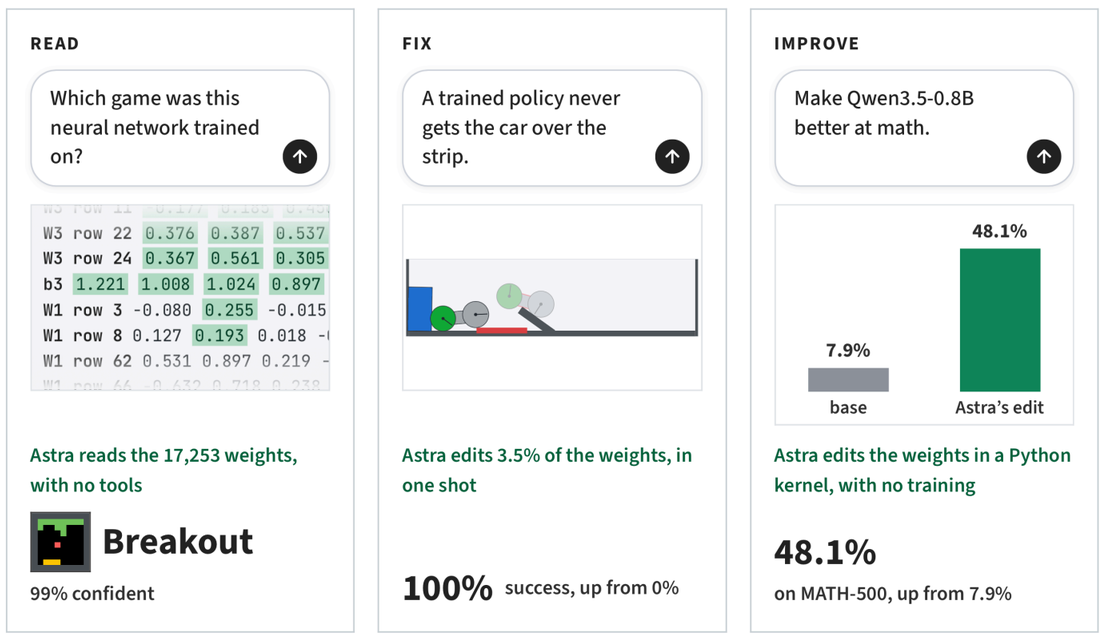

如果让你手写一个会下围棋的神经网络，你会从哪儿下手？如果递给你一份未经任何处理的网络权重，让你预判它的行为，你又该从何看起？对几乎任何人来说，这都是实打实的不可能。

今天，权重要么由优化过程写出来，要么由专门训练来「写权重」的网络生成，要么由形式化程序经编译器产出。而在这篇文章里我们发现：这一代前沿大语言模型，就以自然语言原样使用、不加任何特殊改造，已经开始以一种近乎诡异的方式，擅长围绕自然语言目标去理解和构造神经网络权重。

Weight-Space Programming

这几年，我们一直在用大语言模型优化「文本产物」——提示词，以及围绕提示词搭起来的程序。更晚一些，我们开始让它们去优化整套运行框架，以及训练机器学习模型所用的训练代码与超参数。

我们为这些做法给出的理由，往往是这样一个事实：对文本产物做爬山式搜索，除了让模型来干，我们并不知道还有什么别的、有章法可循的办法；而可微神经网络的权重更新则不然。毕竟，代码人可以用手去「优化」，所以让大语言模型来做是顺理成章的；但权重人没法用手去「优化」，于是它就一直基本留在符号算法的地盘里。

本文分享的是一些非常早期的结果，但它们已足以让我们主张：由推理驱动的优化范式，如今连可微神经网络也要被纳入其中了。

所谓权重空间编程，就是让一个通用大语言模型围绕某段自然语言规格，直接读写网络的权重——不经过优化器，尤其不依靠梯度下降——有时甚至完全不需要环境反馈。

用自然语言**「直接问」**大语言模型，让它从权重里原生找出某个隐藏特性或失效之处、把它修好、或者从零写一个新网络——这正在成为可能。下面我们针对这三类能力分别报告早期而令人振奋的结果，先看小网络，再看真实语言模型：

1. **大语言模型能「读」权重**： 在实验 1 至 3 中，我们向 Astra 提问：某个网络被训练来玩哪款游戏、某个扩散模型画的是什么形状、某个小型语言模型是在哪种语言上训练的。实验 7 里，我们问的是两个语言模型中哪一个被训练成了谄媚模型。

2. **大语言模型能「修」权重**： 在实验 4 中，我们让 Astra 修好一个在某项物理控制任务上失效的网络。实验 8 中，我们让它提升 Qwen3.5-0.8B 的数学能力，而它对权重的修正连指令遵循也一并改善了。

3. **大语言模型能「写」权重**： 实验 5 里，我们让 Astra 给出能玩三款 MinAtar 游戏的网络；实验 6 里，给出一个会下围棋的网络。

Can LLMs understand model behaviors from weights?

我们从一个很小规模的实验开始，看看大语言模型能否理解连续的权重空间——那本质上只是一串数字。

在最初的几个实验里，我们用某种算法训练一些神经网络。如果大语言模型仅凭权重就能说出它的行为，那将极其令人兴奋。

实验1

Astra 能否仅凭权重判断网络是在哪款游戏上训练的?

我们用 PPO 训练神经网络策略来玩四款电脑游戏。四个网络的输入通道相同、可选动作相同、网络尺寸也完全相同，所以除非去读权重，否则分辨不出来。

对每一个这样的网络，我们把它的原始权重作为提示词喂给 Astra，然后问：这个神经网络是在哪款游戏上训练的？我们并没有透露所考虑的游戏有哪些，Astra 却仍然为四个网络全部说出了正确的游戏名。这一点尤其令人兴奋，因为世上的游戏那么多，Astra 本可以从中挑任何一个。

游戏： 我们自己实现的网格版 Breakout、Pong、Pac-Man 和 Freeway，都在同一个 10×10 网格上，用同样的五种动作

网络： MLP 500 → 32 → 32 → 5，tanh（17,253 个权重），每款游戏都一样

输入： 5 个通道的 10×10 网格：智能体、移动物体、奖励目标、障碍物、上一帧

输出： 5 个动作 logit：不动、上、下、左、右

训练： PPO，10 亿步，每款游戏设置相同，每款取 3 个随机种子中最好的一个

Astra 得到的： 全部权重以文本形式给出，以及网格与动作的说明，但没有提到任何游戏名

看起来，Astra 能够仅凭权重特征就推断出每个网络是为哪款游戏而建的。比如，每个输入通道在第一层的权重集中在何处（以 Breakout 为例，智能体的权重落在最下面一行，也就是球拍），以及输出层在区分哪些动作。

实验2

Astra 能否判断扩散模型会生成什么?

接下来，我们想看看这一点能否推广到其他任务与模型。

我们训练扩散模型（DDPM）分别生成圆、三角和方形的图像。然后问 Astra，仅凭权重能否判断这些 DDPM 被训练来生成什么。我们不允许它使用工具，也不允许做前向传播。

模型： 三个 DDPM，生成 12×12 灰度图像，分别对应填充的圆、方形和三角

网络： MLP 160 → 64 → 64 → 144，ReLU（23,824 个权重）

输入： 一张带噪图像（144 个像素）和扩散步（16 个数）

输出： 干净图像（144 个像素）

训练： Adam，40,000 步，批大小 512

Astra 得到的： 全部权重以文本形式给出，不告知任何形状名，并被告知不得计算任何前向传播

Astra 仅凭权重就判断出了每个模型生成什么。它在输出层里找到了形状：每个隐藏单元的权重画出形状边缘的一小段，而它就只画这些边缘。有意思的是，它把每个形状都画成了轮廓，忽略了真实模型生成的是填充图形。这个错误多少说明，它并不是靠计算前向传播，而是真的在读权重的结构／几何。

实验3

Astra 能否仅从网络的中间部分判断语言模型学到了什么?

在上面前两个实验里，Astra 其实并没有看到完整网络，只读第一层或最后一层也能蒙混过关。对更大的（尤其是语言）模型和我们真正关心的问题，这并不是一个可扩展的策略，因为它们如何处理、如何想通自己的输入，往往发生在中间层。所以接下来，我们把第一层和最后一层拿掉，只把中间层留给 Astra。

我们训练三个小语言模型（7.2M 参数）做下一字符预测，分别用 Python 代码（该 Python 代码数据集，以文件列表形式给出，并附一个重建它的脚本：GitHub）、用字母（罗马字）书写的日语，以及英语。然后我们去掉了输入层和输出层，只把中间四个 transformer 块交给 Astra。没有这两层，权重里没有任何东西说明哪个字符是哪个，模型也无法在任何文本上运行。Astra 可以用 Python 分析权重，但不得让网

络或其任何一层在任何输入上运行。

我们问：“这个网络是在哪种语言上训练的，它的 24 个注意力头各自在做什么？”Astra 为三个网络都说对了语言，两次尝试都是如此。它还找出了每一个复制头（归纳头），也就是让模型能够重复此前见过的文本的那些头，并且没有把任何其他头说成复制头。

训练语言	Astra 的答案（及置信度），两次尝试	Astra 指出的复制头	复制头真值
Python	Python (0.56)，Python (0.52)	2.1, 3.1, 3.5	2.1, 3.1, 3.5
Romaji	romaji (0.55)，romaji (0.62)	3.3	3.3
English	English (0.58)，English (0.48)	3.1	3.1

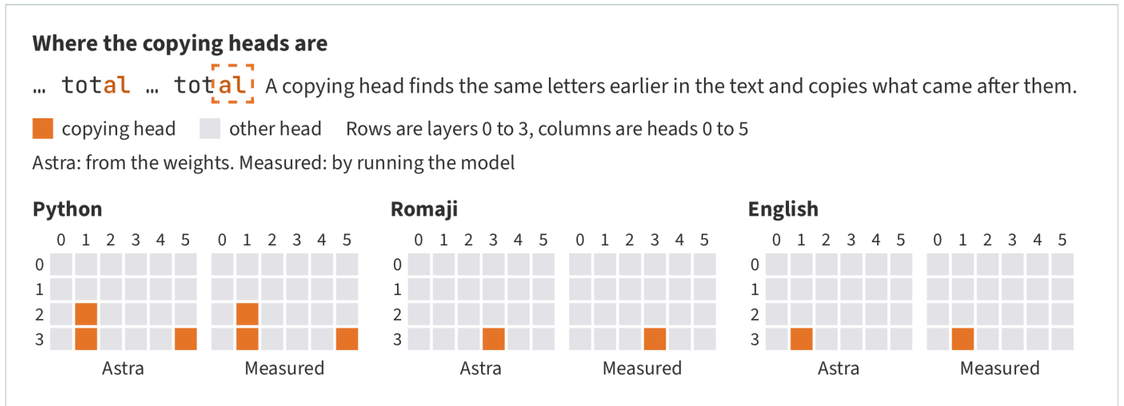

Figure 1: The copying heads Astra read from the weights match the measured ones in all three models.

推理是这样走的。为了把 Python 分辨出来，Astra 去找复制头，也就是让模型能够重复前文、比如在前文出现过 total 时把 tot 补成 total 的那些头。它没有运行任何东西，就找到了一个只回看一个字符的第一层头，然后通过相乘权重矩阵，找到后面那些用这个头带来的信息去搜索的头（图 1）。我们发现，这实际上是 Elhage 等人提

出的一种方法，而我们从未向 Astra 提过。代码里名称的重复远多于散文，所以许多复制头都指向了 Python。

罗马字则是以另一种方式凸显出来的：在给它的四个块中，最后一块（不是被移除的输出层）写出的方向更少，仿佛模型需要区分的字母更少。确实，罗马字从不使用 q、l、v、x 这类字母。

到目前为止，Astra 只读了权重。现在，我们问 Astra 是否知道怎么写权重。

实验4

Astra 能否通过编辑权重修好一个失效的网络？

我们训练一个 PPO 网络来操控一辆小车，使它能在 Kinetix 环境中冲上一段斜坡。为此，它需要先倒车一段距离，以便有足够的助跑距离加速足够久、越过斜坡。然而 PPO 网络收敛到了一个局部最优策略：径直朝斜坡开过去，然后卡住。

我们把权重、场景描述和一段录制的回合交给 GPT-6 Astra，让它解释网络为什么失败，然后通过写出新权重来修好它。在一次没有任何工具的尝试中，Astra 的编辑让小车在全部 1,024 个回合中都成功，改动了 3.5% 的权重。

任务： Kinetix 的小车冲坡关卡：小车必须先倒车，然后跃过一条红色带子到达蓝色方块

网络： Kinetix 官方 actor：679 → 128（ReLU）→ 五层 128（tanh）→ 16（171,664 个权重）

输入： 679 个描述场景的数：每个物体的位置、速度和形状，以及关节

输出： 16 个 logit，对应马达和推进器动作

训练： 官方 PPO，10 亿步。小车在 256 个回合中从未成功（它卡在斜坡上）

Astra 得到的： 全部权重、场景，以及网络在一段录制回合中的结果。它被要求解释失败，并在一次回复中只修正其成因

从环境上下文和 PPO 网络的轨迹中，Astra 认定网络已经收敛到一个局部最优。通过对权重做最小的编辑，Astra 把策略改成先倒车、再全速向前开。Astra 的推理展示了它是怎么做的：它通过每层几个单元增加了一条小的独立通路，用来读取小车的位置和速度，一旦绿色轮子越过红色带子，这条通路就关闭，剩下的由训练好的网络来开。

实验5

大语言模型能否从零写权重?

现在看看 Astra 能否零样本地从零写一个神经网络。

我们取三款 MinAtar 游戏：Breakout、Seaquest 和 Asterix。对每一款，我们把游戏规则和源代码、以及对应的网络交给 Astra。它接触不到数据、损失、梯度，也没有工具。我们也不允许 Astra 在环境中让网络跑起来。仅凭网络权重和环境描述，Astra 直接以文本生成新的权重，之后我们评测这个新网络。

Astra 生成的网络在三款游戏上都击败了训练 1 亿步的 PPO。面对训练 5 亿步的 PPO，它们在 Breakout 上拿到 20 倍的分数，在 Asterix 上与之接近，在 Seaquest 上达到其分数的 60%。

游戏	PPO，1 亿步	PPO，5 亿步	Astra，一次性
Breakout	15.8	25.3	517.4
Seaquest	5.6	88.9	53.1
Asterix	25.8	55.2	53.2

游戏： MinAtar 中的 Breakout、Seaquest 和 Asterix，10×10 网格

网络： 600 → 32 → 32 → 6（tanh），与 PPO 网络形状相同，每个权重都从 0 开始

输入与输出： 6 个通道的网格（玩家、危险、奖励、投射物、轨迹、量表），以及 6 个动作 logit

Astra 得到的： 游戏规则和源代码、输入输出布局，以及网络如何计分

训练： 无：没有数据，没有损失，没有梯度，也没有工具。Astra 在一次回复中以文本写出权重，网络在计分之前从未玩过

计分： 1,000 个回合，动作从网络采样，粘滞动作 0.1，最多 10,000 步。PPO：取 3 至 10 个随机种子中最好的一个

它是怎么做到的：Astra 推理出它希望每个网络实现的程序，再把它们转成神经网络形式。例如在 Breakout 中，Astra 把第一层「编程」为计算球会落在哪里，第二层则被编程为把球拍移到那个位置。

到目前为止，我们考察的大多数网络，其权重都能直接放进 Astra 的上下文，而且我们没有启用工具。这些限制是为了聚焦于一个事实：大语言模型原生就具备某种解读权重空间的能力。

从这里往后，我们想推进权重空间编程的能力，去考虑更贴近现实世界的场景：网络放不进上下文，而工具可以辅助大语言模型理解／书写权重空间。

如果让你手写一个会下围棋的神经网络，你会从哪儿下手？如果递给你一份未经任何处理的网络权重，让你预判它的行为，你又该从何看起？对几乎任何人来说，这都是实打实的不可能。

今天，权重要么由优化过程写出来，要么由专门训练来「写权重」的网络生成，要么由形式化程序经编译器产出。而在这篇文章里我们发现：这一代前沿大语言模型，就以自然语言原样使用、不加任何特殊改造，已经开始以一种近乎诡异的方式，擅长围绕自然语言目标去理解和构造神经网络权重。

Weight-Space Programming

这几年，我们一直在用大语言模型优化「文本产物」——提示词，以及围绕提示词搭起来的程序。更晚一些，我们开始让它们去优化整套运行框架，以及训练机器学习模型所用的训练代码与超参数。

我们为这些做法给出的理由，往往是这样一个事实：对文本产物做爬山式搜索，除了让模型来干，我们并不知道还有什么别的、有章法可循的办法；而可微神经网络的权